

AI 求职智能匹配智能体 — 方案说明

一、问题诊断

学生求职面临两大痛点：(1) 岗位海量，逐一甄别与自身背景、能力、兴趣的匹配度耗时巨大；(2) 锁定心仪岗位后，无法判断简历与岗位的契合程度，也不清楚如何优化以通过简历初筛（ATS/HR 筛选）。本方案聚焦这两点，构建一个"先精准匹配、再针对性优化"的闭环智能体。

二、方案设计

产品形态为 Next.js 全栈 Web 应用，流程分三步：

1. 简历解析：用户粘贴简历，Claude 抽取为结构化画像（技能、经历、教育、求职意向）。
 2. 岗位智能匹配：将画像与岗位库交给 Claude 做多维语义评估（技能契合、经历相关、意向匹配、经验要求），输出 Top 岗位、匹配度评分及一句话匹配理由，解决"找岗难"。
 3. 简历诊断优化：针对用户选定岗位，对比简历与 JD，给出预估初筛命中率、命中/缺失关键词、可执行优化建议及按 STAR 法则的改写示例，直接提升"初筛命中率"。
- 岗位库覆盖学生高频领域（互联网研发、产品运营等），含应届校招与实习岗，字段对齐真实招聘平台 JD 结构。

三、AI 工具选型理由

- 大模型选 Claude：在中文语义理解、结构化抽取与长文本指令遵循上表现稳定，匹配理由和简历建议的专业度与可读性高。
- 召回方案的迭代：初设计采用"向量 embedding 召回 + LLM 精排"。实测可用的推理网关仅支持 Claude 对话、不提供 embedding 接口，遂调整为"Claude 直接对岗位库语义排序"。岗位库规模可控，单次调用即可完成召回+排序+解释，架构更简、无额外服务依赖，召回质量反而更优。此为关键工程权衡。

四、关键配置

- 适配层抽象 Claude 接口，支持 ANTHROPIC_BASE_URL 切换官方/网关，密钥仅经环境变量注入、不入代码库。
- LLM 输出强约束为 JSON，并做容错提取（去除包裹、截取首尾花括号），保证解析稳定。
- 匹配综合分由模型按多维度给出，前端按命中率分级着色展示，交互直观。

五、迭代记录

1. 搭建 Next.js + 三个 API（解析/匹配/优化）骨架。
2. 移除需原生编译的本地 embedding 依赖，避免部署障碍。
3. 因网关不支持 embedding，召回改为 Claude 直接排序。
4. 修复 JSON 解析：弃用 prefill，改为稳健的文本提取。
5. 端到端联调通过并部署公网。

六、效果评估

以"Java 后端 2026 届"简历实测：匹配结果将"后端开发（校招）95 分""Java 后端实习 88 分"准确置顶，相关岗位（测试开发等）合理降权；针对后端岗的诊断准确识别出"微服务/分布式/高并发"等缺失关键词，并给出可量化的 STAR 改写示例。匹配精准、建议可落地，验证了方案的有效性。